

Aprendizaje Maquinal en Pokémon Showdown: Agrupación, Clasificación y Aprendizaje por Refuerzo

Gabriel Andrés Anzola Tachak
Universidad Nacional de Colombia
Colombia
ganzola@unal.edu.co

Nicolas David Moreno Villanueva
Universidad Nacional de Colombia
Colombia
nimorenov@unal.edu.co

Abstract—Cada partida de Pokémon Showdown deja un replay público: una decisión humana bajo incertidumbre, registrada turno a turno. Sobre 484,130 batallas reales del formato Gen 8 Random Battle aplicamos una técnica de cada familia del aprendizaje maquinal. K-Means encuentra apenas dos arquetipos de equipo —ofensivo y defensivo— débilmente separados ($\text{silhouette}=0.136$), lo esperable cuando todos los equipos salen del mismo sorteo. XGBoost resulta interesante por lo que *no* encuentra: el perfil estadístico de un equipo casi no delata el estilo con el que gana (59% de exactitud frente a un 54% de base), señal de que el estilo se decide jugando y no armando el equipo. Por último, un agente de Q-Learning tabular aprende desde cero a ganar el 76.6% de sus partidas contra un rival aleatorio, con un espacio de estados anclado en lo que de verdad decide un turno: velocidad, ventaja de tipo y HP. Las tres técnicas atacan el mismo corpus desde ángulos distintos —describir, explicar y actuar— y comparten esos ejes tácticos del dominio.

Index Terms—aprendizaje por refuerzo, gradient boosting, K-Means, Pokémon Showdown, agente autónomo

I. INTRODUCCIÓN

Pokémon es una franquicia de videojuegos de rol creada por Game Freak en 1996, con más de 480 millones de copias vendidas a marzo de 2024 [1]. Su mecánica central son los combates por turnos entre criaturas llamadas Pokémon, cada una con estadísticas base — puntos de vida (HP, del inglés *Hit Points*), Ataque, Defensa, Velocidad —, tipos elementales y hasta cuatro movimientos. El combate es un duelo de información incompleta: cada turno ambos jugadores eligen una acción simultáneamente, a ciegas respecto a la del rival.

Dos factores dominan la táctica: la **ventaja de tipo** y la **velocidad**. Un movimiento de tipo Agua hace el doble de daño a un Pokémon de tipo Fuego, pero la mitad a uno de Planta — hay dieciocho tipos con relaciones asimétricas entre ellos. La velocidad determina quién actúa primero: el Pokémon más veloz puede noquear al rival antes de recibir contraataque, lo que convierte la composición del equipo en una decisión estratégica de alto impacto.

Pokémon Showdown [2] es un simulador de combate de código abierto con más de 100,000 usuarios activos que replica fielmente estas mecánicas en el navegador. Cada partida queda guardada como un replay público, creando un corpus único: decisiones humanas bajo incertidumbre completamente observables y reproducibles.

El formato **Gen 8 Random Battle** (generación 8, Pokémon Sword/Shield, 2019) asigna equipos aleatorios de seis Pokémon al inicio de cada batalla, eliminando la fase de construcción de equipo y concentrando el desafío exclusivamente en las decisiones durante el combate. La generación 8 introduce además **Dynamax**: un Pokémon puede duplicar temporalmente sus HP durante tres turnos, una palanca estratégica más sobre la mesa.

Este trabajo extrae conocimiento de 484,130 batallas reales [3] con tres técnicas complementarias: (1) K-Means descubre si existen arquetipos naturales de equipo; (2) XGBoost mide cuánto delata el perfil de un equipo el estilo con que gana; (3) un agente de aprendizaje por refuerzo aprende a jugar a partir de los mismos factores tácticos que las dos primeras ponen sobre la mesa. El código fuente está disponible en <https://github.com/gabotachak/pokemon-agent>.

La contribución no está en superar un récord de rendimiento, sino en recorrer las tres familias del aprendizaje maquinal sobre un mismo corpus dejando que cada una responda la pregunta que sabe responder: K-Means describe, XGBoost explica y el agente actúa. Las tres se sostienen sobre los mismos ejes del dominio —velocidad, ventaja de tipo y HP—, lo que da unidad al recorrido.

II. TRABAJO RELACIONADO

El aprendizaje por refuerzo (RL, del inglés *Reinforcement Learning*) ha sido aplicado a videojuegos desde los años 90, desde programas de Backgammon [4] hasta sistemas de nivel profesional. En el dominio de Pokémon, Sahovic [5] desarrolló poke-env, la librería Python estándar para conectar agentes al simulador Pokémon Showdown, y demostró que agentes basados en redes neuronales profundas (DQN, *Deep Q-Network*) superan el 80% de victorias contra oponentes aleatorios en Gen 1. Jin et al. [6] compilaron PokeChamp, un dataset de millones de batallas con modelos de aprendizaje por imitación — aprender a replicar las acciones de jugadores expertos.

En mayor escala, AlphaStar [7] y OpenAI Five [8] demostraron que RL con redes profundas puede alcanzar nivel profesional en juegos como StarCraft II y Dota 2, aunque con recursos computacionales inaccesibles para la mayoría de contextos de investigación.

A diferencia de estos trabajos, este enfoque combina agrupación no supervisada, clasificación supervisada y RL tabular

interpretable en un flujo coherente sobre datos Gen 8, priorizando la extracción de conocimiento comprensible sobre el rendimiento máximo.

III. DATASET Y PREPROCESAMIENTO

A. Dataset

El corpus HolidayOugi/pokemon-showdown-replays [3] contiene 31.7 millones de replays. Se seleccionó el formato `gen8randombattle` (**484,130 batallas**), descargando únicamente los 3 archivos `parquet` correspondientes para evitar la descarga completa de 66 GB.




Fig. 1: Duración de batallas en turnos — la mayoría termina entre 15 y 40.




Fig. 2: Pokémon más frecuentes en el corpus — reflejan el pool aleatorio del formato.

B. Análisis del Log y Extracción de Características

El campo `log` de cada batalla codifica cada evento en líneas del tipo `|COMANDO|argumentos`. Se extrae: los equipos revelados, el ganador, duración, movimientos usados y cambios voluntarios. Los nombres de Pokémon se normalizan y combinan con estadísticas base [9] para calcular promedios por equipo.

TABLE I: CARACTERÍSTICAS DERIVADAS CON SU INTERPRETACIÓN EN CONTEXTO DE COMBATE (SELECCIÓN).

Característica	Interpretación táctica
<code>avg_speed</code>	Velocidad promedio — el Pokémon más veloz actúa primero cada turno
<code>speed_advantage_ratio</code>	Velocidad p1 / p2 — quién controla el ritmo del combate
<code>stat_total_diff</code>	Diferencia de stats totales — proxy de ventaja estadística global
<code>type_coverage</code>	Tipos de movimientos disponibles — amplitud ofensiva del equipo
<code>switch_rate</code>	Cambios por turno del ganador — <i>excluida del clasificador por fuga de información</i> (ver IV-B)
<code>n_fast_pokemon</code>	Pokémon con velocidad >100 — capaces de actuar antes que la mayoría

La **variable objetivo** para clasificación es `winning_action_type`: el tipo de acción más frecuente del jugador ganador. Responde a *¿cómo ganan los que ganan?* Cuatro categorías: movimiento físico, especial, de estado o cambio de Pokémon.

IV. METODOLOGÍA

A. Agrupación — K-Means

¿Existen estilos de equipo naturales en batallas aleatorias, o todos los equipos son estadísticamente indistinguibles?

K-Means [10] es un algoritmo de agrupamiento no supervisado que asigna cada punto al grupo más cercano y recalcula los centros iterativamente hasta convergencia, minimizando la varianza interna de cada grupo:

$$J = \sum_k \sum_{x \in C_k} \|x - \mu_k\|^2 \quad (1)$$

donde μ_k es el centro del grupo k . No requiere etiquetas previas — descubre la estructura que emerge naturalmente de los datos.

Para elegir el número de grupos K , usamos el *silhouette score* [11]: mide qué tan bien separado está cada punto de los demás grupos. Se calcula comparando la cohesión interna con la distancia al grupo vecino más cercano:

$$s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))}, \quad s(i) \in [-1, 1] \quad (2)$$

donde $a(i)$ es la distancia media a los otros puntos del mismo grupo y $b(i)$ la distancia media al grupo vecino más cercano. Valores cercanos a 1 indican grupos bien separados; valores cercanos a 0 indican solapamiento.

Flujo: vectores de equipo (9 características) → normalización → análisis de componentes principales (PCA [12], para reducir a 2 dimensiones y poder visualizar) → K-Means $K=2..10$.




Fig. 3: Inercia y silhouette score para K=2..10. El máximo de silhouette ocurre en K=2.




Fig. 4: Proyección PCA coloreada por grupo. Grupo 0: mayor velocidad. Grupo 1: mayor HP y defensa.




Fig. 5: Radar de centroides normalizados de cada arquetipo de equipo.

Resultado: K=2 con silhouette=0.136. La separación es tenue, y tiene sentido que lo sea: todos los equipos vienen del mismo sorteo aleatorio. Aun así, los centroides dibujan dos perfiles reconocibles — equipos veloces y ofensivos frente a equipos resistentes y defensivos.

B. Clasificación — XGBoost

¿Delata el perfil estadístico de un equipo la estrategia con la que ganará?

XGBoost [13] implementa *gradient boosting*: construye un conjunto (*ensemble*) de árboles de decisión de forma aditiva, donde cada árbol nuevo corrige los errores del anterior. El modelo final es la suma de T árboles:

$$\hat{y} = \sum_{t=1}^T f_t(x) \quad (3)$$

En cada iteración, se elige el árbol f_t que minimiza la pérdida acumulada más un término $\Omega(f_t)$ que penaliza árboles innecesariamente complejos para evitar sobreajuste:

$$\mathcal{L}^{(t)} = \sum_i \ell(y_i, \hat{y}_i^{(t-1)} + f_t(x_i)) + \Omega(f_t) \quad (4)$$

Además de predicciones, XGBoost cuantifica la **importancia** de cada característica: cuánto contribuyó cada variable al conjunto.

Configuración: 21 características, split 80/20 estratificado, 1000 árboles máximo con parada temprana a los 20 sin mejora, GPU. Mejor iteración: 779 árboles.

El conjunto excluye `switch_rate` (cambios del ganador / turno) por fuga de información: `switch_rate` se deriva del conteo de cambios del ganador, y ese mismo conteo define la clase `switch` del objetivo, lo que vuelve circular la relación. Con esa característica presente la clase `switch` alcanza AUC 0.955; sin ella cae a AUC 0.693 y recall 0.01 —impredecible desde el perfil de equipo—, confirmando que su predictibilidad provenía por completo de la circularidad. Las métricas siguientes corresponden al modelo sin `switch_rate`.

TABLE II: MÉTRICAS POR CLASE SIN `SWITCH_RATE` (MODELO HONESTO). EXACTITUD GLOBAL: 59.0% (LÍNEA BASE: 54%). EL F1 PROMEDIO ES PONDERADO; EL AUC-ROC PROMEDIO ES SIMPLE. AUC-ROC MIDE LA CAPACIDAD DISCRIMINATIVA: 1.0 ES PERFECTO, 0.5 EQUIVALE A CLASIFICACIÓN ALEATORIA.

Clase	Precisión	Recall	F1	AUC-ROC
physical	0.624	0.916	0.742	0.751
special	0.458	0.235	0.310	0.739
status	0.444	0.276	0.340	0.758
switch	0.462	0.014	0.027	0.693
promedio			0.520	0.735




Fig. 6: Importancia de características por contribución al conjunto.




Fig. 7: Matriz de confusión normalizada.




Fig. 8: Curvas ROC por clase (modelo sin switch_rate). switch es ahora la clase más difícil (AUC 0.693): el comportamiento de cambio no es predecible desde el perfil estadístico de los equipos.

Las variables que más pesan son `n_turns` (la duración de la batalla) y la diversidad de tipos de ambos equipos; el resto aporta poco y `speed_advantage_ratio` queda de último. Conviene leer esto con cuidado: `n_turns` solo se conoce cuando la batalla termina, así que el modelo no anticipa el estilo ganador desde la mesa de armado, sino que lo *explica* en retrospectiva a partir de cómo se desarrolló el combate. Despojado de esas pistas dinámicas, el perfil estático del equipo apenas se distingue del azar. El F1 bajo en `special` y `status` refleja el desbalance —`physical` concentra el 54% de los registros— y `switch` se vuelve la clase más esquiva (recall 0.01) una vez retirada `switch_rate`.

C. Aprendizaje por Refuerzo — Q-Learning

¿Puede un agente aprender a jugar Pokémon Showdown por prueba y error, sin que se le diga explícitamente qué hacer?

El aprendizaje por refuerzo [14] entrena un agente que interactúa con un entorno: toma acciones, recibe recompensas y ajusta su comportamiento para maximizar la recompensa acumulada a largo plazo. No requiere ejemplos etiquetados ni reglas predefinidas — el agente descubre qué funciona por experiencia directa.

Q-Learning [15] es uno de los algoritmos más simples de RL. Aprende una tabla $Q(s, a)$ que estima la recompensa futura esperada de tomar acción a en estado s . Tras cada turno, el agente actualiza su estimación:

$$Q(s, a) \leftarrow Q(s, a) + \alpha \left[r + \gamma \max_{a'} Q(s', a') - Q(s, a) \right] \quad (5)$$

El término $r + \gamma \max_{a'} Q(s', a')$ combina la recompensa inmediata r con el mejor valor futuro conocido desde el nuevo estado s' , descontado por $\gamma = 0.9$. La diferencia con $Q(s, a)$ es el error de predicción que el agente corrige con tasa $\alpha = 0.1$.

Diseño del espacio de estados: las variables de estado se anclan en los factores tácticos del dominio descritos en la Introducción (velocidad y ventaja de tipo) y en la estructura del combate, no en derivaciones automáticas de K-Means/ XGBoost:

TABLE III: VARIABLES DE ESTADO DEL AGENTE Y SU FUNDAMENTO. SU PRODUCTO CARTESIANO DEFINE 27,648 ESTADOS TEÓRICOS. LA VELOCIDAD Y LA VENTAJA DE TIPO COINCIDEN CON LOS FACTORES QUE LA INTRODUCCIÓN IDENTIFICA COMO TÁCTICAMENTE DOMINANTES; `SPEED_ADVANTAGE_RATIO` TIENE BAJO PODER PREDICTIVO EN EL MODELO, POR LO QUE `CAN_OUTSPEED` SE INCLUYE POR SU RELEVANCIA TÁCTICA EN EL DOMINIO.

Variable	Valores	Fundamento
<code>hp_self/opp</code>	4 cuartiles	Discretización fija de HP en cuartiles (no derivada del corpus)
<code>type_advantage</code>	{-1,0,+1}	Chart de efectividad de tipos (mecánica del juego, vía <code>poke-env</code>)
<code>can_outspeed</code>	booleano	Factor velocidad, dominante en la táctica (Introducción)
<code>team_size_self/opp</code>	1-6	Pokémon vivos — estado de combate
<code>n_available_moves</code>	1-4	Estructura del espacio de acción
<code>has_switch</code>	booleano	Disponibilidad de cambio — espacio de acción

El agente juega contra un **RandomPlayer** — oponente que elige acciones uniformemente al azar, sin considerar el estado del combate. Sirve como línea base para verificar que el agente aprende algo.

Espacio de acciones: 9 fijas — slots 0-3 son movimientos, slots 4-8 son cambios de Pokémon. Acciones inválidas caen al primer movimiento disponible.

Señal de recompensa: +1.5 por daño infligido, -1.0 por daño recibido sin contraatacar, ± 0.5 por calidad del cambio, ± 10 por victoria o derrota al terminar la batalla.

Exploración ϵ -greedy: el agente comienza eligiendo al azar ($\epsilon=1.0$) y decae hasta $\epsilon=0.05$ a lo largo de 1,500 de los 2,000 episodios totales.




Fig. 9: Tasa de victorias promedio (ventana de 100 episodios) y decaimiento de ϵ durante el entrenamiento.

V. RESULTADOS Y DISCUSIÓN

K-Means: $K=2$, `silhouette`=0.136. PCA captura 40.4% de varianza en 2 dimensiones. Los centroides son interpretables como estilos ofensivo y defensivo débilmente separados, coherente con equipos de un pool aleatorio común.

XGBoost: 59.0% de exactitud, +5 puntos sobre la línea base (54%). Las variables más informativas son `n_turns` y `type_diversity`; `speed_advantage_ratio` queda en último lugar, de modo que ninguna característica del perfil

de equipo domina la predicción del estilo ganador. El F1 bajo en `special` (0.310) y `status` (0.340) refleja el desbalance de clases — `physical` domina el 54% de los registros — y `switch` es la clase menos predecible (F1 0.027): el estilo de cambio no se infiere desde los perfiles estadísticos de los equipos.

Q-Learning: el agente arranca por debajo de la línea base del 50% frente al `RandomPlayer` —lastrado por las acciones inválidas durante la exploración pura— y la cruza en unos cien episodios, hasta estabilizarse en 76.6% de victorias tras 2,000 episodios. Solo visita 2,039 de los 27,648 estados teóricos posibles (un 7%), y ahí está parte de la gracia del enfoque tabular: el agente aprende únicamente sobre situaciones que de verdad ocurren, sin malgastar capacidad en combinaciones imposibles. La tabla Q queda completamente abierta a inspección — a diferencia de una red neuronal, puede leerse directamente qué acción prefiere el agente en cada situación.

Coherencia entre técnicas: las tres operan sobre el mismo corpus y comparten un marco táctico común (velocidad, ventaja de tipo, HP). El vínculo es conceptual: la velocidad —destacada en la Introducción y materializada como `can_outspeed` en el agente— ancla las tres técnicas en los mismos factores del dominio, con independencia de que `speed_advantage_ratio` tenga bajo poder predictivo en XGBoost. El espacio de estados del agente se fundamenta en la mecánica del juego, corroborada por el análisis descriptivo, no en una derivación automática desde K-Means/XGBoost.

Limitaciones: (1) el 76.6% es contra un `RandomPlayer` — línea base débil— y no generaliza a oponentes más fuertes; (2) Q-Learning tabular no escala a estados continuos; (3) el agente usa el dataset de forma solo indirecta (no entrena sobre los replays, sino sobre partidas en vivo); (4) `n_turns`, la característica más informativa de XGBoost, es post-hoc, por lo que la tarea de clasificación es descriptiva más que predictiva en sentido estricto.

Comparativa de las tres técnicas: las tres responden preguntas distintas y no compiten entre sí (Tabla 4). K-Means y XGBoost extraen conocimiento *descriptivo* y *predictivo* directamente del corpus histórico; Q-Learning produce conocimiento *procedimental* — una política de juego — interactuando con el entorno en vivo. K-Means y Q-Learning ofrecen alta interpretabilidad (centroides legibles, tabla Q inspeccionable), mientras XGBoost sacrifica transparencia por capacidad predictiva. La complementariedad es la clave: las tres comparten un marco táctico común anclado en la mecánica del juego (velocidad, ventaja de tipo, HP), no una derivación automática del estado del agente desde las dos primeras.

TABLE IV: COMPARATIVA DE LAS TRES TÉCNICAS SEGÚN PARADIGMA, ENTRADA, CONOCIMIENTO EXTRAÍDO, MÉTRICA E INTERPRETABILIDAD.

Dimensión	K-Means	XGBoost	Q-Learning
Paradigma	No superv.	Supervisado	Refuerzo
Entrada	Vectores de equipo	Características de batalla	Estado en vivo
Conocimiento	Arquetipos	Características explicativas	Política de juego
Métrica	Silueta 0.136	Exactitud 59.0%	Tasa victorias 76.6%
Interpretab.	Alta	Media	Alta
Uso del dataset	Directo	Directo	Indirecto

VI. CONCLUSIONES

- 1) **K-Means** sugiere 2 arquetipos de equipo débilmente separados ($\text{silhouette}=0.136$), con centroides interpretables como estilos ofensivo y defensivo; la baja silueta indica que la separación es tenue, esperable en un pool aleatorio común.
- 2) **XGBoost** predijo el estilo de combate ganador con 59.0% de exactitud (+5 sobre la línea base); ninguna variable del perfil de equipo domina, y el estilo de cambio resultó no predecible desde los perfiles estadísticos.
- 3) **El agente de Q-Learning** alcanzó 76.6% de victorias contra un oponente aleatorio con una tabla Q de 2,039 estados, fundamentada en los factores tácticos del dominio.

La tabla Q inspeccionable permite verificar comportamientos tácticamente coherentes: cambiar de Pokémon ante desventaja de tipo, atacar cuando se puede actuar primero.

Más allá del resultado por técnica, el aporte es metodológico: aplicar una técnica de cada familia —no supervisada, supervisada y de refuerzo— de forma coherente sobre un mismo corpus, con atención al rigor en cada paso (exclusión de características con fuga, delimitación del alcance de cada resultado) y cifras honestas: separación débil de clústeres en un pool aleatorio común, línea base aleatoria del agente.

A. Trabajo futuro

Tres líneas extienden este trabajo. Primero, reemplazar la tabla Q por una red Q profunda (DQN) capaz de operar sobre estados continuos sin la discretización en rangos. Segundo, sustituir al RandomPlayer por oponentes más fuertes —agentes heurísticos o el propio agente mediante *self-play*— para superar el techo que impone una línea base aleatoria. Tercero, extraer reglas de juego en lenguaje natural directamente de la tabla Q, convirtiendo la política aprendida en conocimiento explícito y auditable.

REFERENCES

- [1] The Pokémon Company, “Pokémon in Figures.” [Online]. Available: <https://corporate.pokemon.co.jp/en/aboutus/figures/>
- [2] Smogon University, “Pokémon Showdown Battle Simulator.” [Online]. Available: <https://github.com/smogon/pokemon-showdown>

- [3] HolidayOugi, “Pokémon Showdown Replays Dataset.” [Online]. Available: <https://huggingface.co/datasets/HolidayOugi/pokemon-showdown-replays>
- [4] G. Tesauro, “TD-Gammon, a Self-Teaching Backgammon Program,” *Machine Learning*, vol. 14, pp. 397–422, 1994.
- [5] H. Sahovic, “poke-env: A Python Interface for Pokémon Showdown.” [Online]. Available: <https://github.com/hsahovic/poke-env>
- [6] Y. Jin and others, “PokeChamp: an Expert-level Minimax Language Agent for Competitive Pokémon,” *arXiv:2506.04765*, 2025.
- [7] O. Vinyals and others, “Grandmaster Level in StarCraft II Using Multi-Agent Reinforcement Learning,” *Nature*, vol. 575, pp. 350–354, 2019.
- [8] C. Berner and others, “Dota 2 with Large Scale Deep Reinforcement Learning,” technical report arXiv:1912.06680, 2019.
- [9] PokeAPI, “The RESTful Pokémon API.” [Online]. Available: <https://pokeapi.co/>
- [10] J. MacQueen, “Some Methods for Classification and Analysis of Multivariate Observations,” in *Proc. 5th Berkeley Symp. Mathematical Statistics and Probability*, 1967, pp. 281–297.
- [11] P. J. Rousseeuw, “Silhouettes: A Graphical Aid to the Interpretation and Validation of Cluster Analysis,” *Journal of Computational and Applied Mathematics*, vol. 20, pp. 53–65, 1987, doi: 10.1016/0377-0427(87)90125-7.
- [12] I. T. Jolliffe, *Principal Component Analysis*, 2nd ed. Springer, 2002.
- [13] T. Chen and C. Guestrin, “XGBoost: A Scalable Tree Boosting System,” in *Proc. 22nd ACM SIGKDD Int. Conf. Knowledge Discovery and Data Mining*, 2016, pp. 785–794. doi: 10.1145/2939672.2939785.
- [14] R. S. Sutton and A. G. Barto, *Reinforcement Learning: An Introduction*, 2nd ed. MIT Press, 2018.
- [15] C. J. C. H. Watkins and P. Dayan, “Q-Learning,” *Machine Learning*, vol. 8, pp. 279–292, 1992.